


1. Zagregowane statystyki ogólne

Zestawienie prezentuje skuteczność poszczególnych trybów, w tym wskaźnik sukcesu (procent poprawnych odpowiedzi) oraz statystyki mechanizmu ostrzeżeń (samokrytyki).


- **Tryb: Fast (Szybki)**
- **Testy:** 79 (100% poprawności) / 91 (Częściowo) / 109 (Wszystkie)
- **Wskaźnik sukcesu (Success Rate):** 78.9% (Całkowita liczba prób: 327)
- **Ostrzeżenia (Warnings):** 0 ogółem | Błędne ostrzeżenia: 0
- **Skuteczność ostrzeżeń (wykryte błędy):** 0.0%
- **Ingerencja (błędnie oflagowany sukces):** 0.0%
- **Tryb: Planning (Planowanie)**
- **Testy:** 55 (100% poprawności) / 80 (Częściowo) / 109 (Wszystkie)
- **Wskaźnik sukcesu (Success Rate):** 62.1% (Całkowita liczba prób: 327)
- **Ostrzeżenia (Warnings):** 60 ogółem | Błędne ostrzeżenia: 22
- **Skuteczność ostrzeżeń (wykryte błędy):** 48.4%
- **Ingerencja (błędnie oflagowany sukces):** 10.8%
- **Tryb: Chain_of_draft (Łańcuch szkiców)**
- **Testy:** 43 (100% poprawności) / 80 (Częściowo) / 109 (Wszystkie)
- **Wskaźnik sukcesu (Success Rate):** 56.6% (Całkowita liczba prób: 327)
- **Ostrzeżenia (Warnings):** 50 ogółem | Błędne ostrzeżenia: 15
- **Skuteczność ostrzeżeń (wykryte błędy):** 35.2%
- **Ingerencja (błędnie oflagowany sukces):** 8.1%
- **Tryb: Reflection_refine (Refleksja i poprawa)**
- **Testy:** 69 (100% poprawności) / 86 (Częściowo) / 109 (Wszystkie)
- **Wskaźnik sukcesu (Success Rate):** 72.2% (Całkowita liczba prób: 327)
- **Ostrzeżenia (Warnings):** 48 ogółem | Błędne ostrzeżenia: 23
- **Skuteczność ostrzeżeń (wykryte błędy):** 52.7%
- **Ingerencja (błędnie oflagowany sukces):** 9.7%

2. Analiza skuteczności ogólnej (Heatmaps)

Poniższe wykresy mapują ogólną skuteczność w poszczególnych testach, kategoryzując wyniki na pełen sukces (100%), częściowy (>50%) oraz niepowodzenie, a także prezentując ciągły rozkład proporcji sukcesu.



Wykres 1: Kategoryczna siatka pokazująca poziomy zaliczenia testów (100%, >50%, Częściowe, Błąd) oraz znaczniki autokorekty. Zawiera oś Y z indeksami wszystkich testów.




Wykres 2: Ciągły gradient (Czerwony-Żółty-Zielony) mapujący dokładny współczynnik sukcesu. Tło maskuje nieistniejące testy.


Wnioski: Ogólny obraz na obu mapach ciepła wskazuje, że **tryb szybki (Fast) działa najlepiej**. Spośród architektur "myślących", tryb *Reflection refine* osiąga wyniki najbardziej zbliżone do trybu szybkiego i jest obiektywnie najlepszym z wariantów opartych na cyklu myślenia.

3. Skuteczność w podziale na bloki i typy zadań

Kolejne wykresy analizują wskaźnik sukcesu (w przedziale 0.0 - 1.0) w odniesieniu do konkretnych bloków tematycznych testów oraz złożoności zadań (teoria, kodowanie, CLI).



Wykres 3: Porównanie współczynnika sukcesu pogrupowane według bloków testowych (np. Algorithms, CLI) przy zachowaniu stałej kolejności trybów.




Wykres 4: Porównanie współczynnika sukcesu z podziałem na stopień złożoności zapytania: Teoria (1), Kodowanie (2) oraz CLI (3).

Wnioski:


- Wykres 3: Tryby Planning oraz Chain of draft ustępują trybowi szybkiemu we wszystkich blokach testowych. Z kolei tryb Reflection refine wykazuje lepsze rezultaty (przewyższające tryb szybki) **tylko w konkretnych blokach**: L2, L3 (tutaj odnotowano największą różnicę na korzyść trybu myślącego) oraz L7.
- Wykres 4: W ogólnym rozrachunku złożoności zadań, skuteczność trybu Reflection refine jest porównywalna z trybem szybkim.

4. Analiza czasu przetwarzania (Opóźnienia)


Rozkłady opóźnień pokazują narzut czasowy generowany przez tryby z cyklem myślenia oraz wskazują na ewentualne problemy sprzętowe (np. ograniczenia VRAM).



Wykres 5: Wykresy pudełkowe (boxplots) pokazujące rozkład czasu przetwarzania (w sekundach) dla każdego z trybów.



Wykres 6: Segmentowane wykresy pudełkowe oceniające, jak różne bloki tematyczne wpływają na czas generowania odpowiedzi.




Wykres 7: Wykresy pudełkowe porównujące czas przetwarzania bezpośrednio w zadaniach Teoretycznych, Kodowania i CLI.

Wnioski: Wykresy wyraźnie obrazują **bardzo duże spowolnienie** w trybach myślących. Tryb *Reflection refine* pozostaje najbliższy trybu szybkiego pod względem wydajności czasowej. Wynika to z faktu, że jest to architektura najprostsza – opiera się na ponownej próbie wygenerowania całości od nowa z uwzględnieniem samokrytyki. Bliskość wyników do trybu szybkiego tłumaczy fakt, że w większości przypadków model zatrzymywał się już po 1. próbie. Widoczne są jednak znaczne wartości szczytowe (outliery), które pojawiały się, gdy model kilkakrotnie próbował poprawić odpowiedź.


5. Ewaluacja mechanizmu samokrytyki (Ostrzeżeń)

Ostatnia sekcja raportu skupia się na tym, czy mechanizmy samooceny modeli potrafią trafnie ocenić jakość własnych odpowiedzi. (Uwaga: Zgodnie z analizą, pominięto macierz wyłącznie dla kodowania, by uniknąć duplikacji wniosków).



Wykres 8: Macierz pomyłek (Confusion Matrix) ostrzeżeń dla wszystkich testów. Pokazuje wartości: True Positive (ostrzeżenie przy błędzie), True Negative (brak ostrzeżenia przy sukcesie), False Positive (ostrzeżenie mimo sukcesu) oraz False Negative (brak ostrzeżenia przy błędzie).


Wniosek do wykresu 8: Mechanizm ostrzeżeń przepuszcza bardzo dużo błędów (wysoki odsetek False Negative), a jednocześnie nierzadko klasyfikuje poprawne odpowiedzi jako błędne (False Positive).



Wykres 9: Dwukierunkowy wykres słupkowy. Oś Y skierowana w górę (kolory niebieski/zielony) pokazuje odsetek prawidłowych ostrzeżeń (zgłoszonych przy błędnej odpowiedzi). Oś Y skierowana w dół (kolory pomarańczowy/czerwony) pokazuje odsetek błędnych ostrzeżeń (zgłoszonych przy prawidłowej odpowiedzi) na dany blok testowy.

Wniosek do wykresu 9:

- Ostrzeżenia okazują się w pełni efektywne dla: L1 (Chain of draft), L5 (Chain of draft) oraz L7 (Reflection refine).
- Dla bloku L4 ostrzeżenia w ogóle nie wystąpiły.
- W przypadku wybranych kombinacji testów i trybów odnotowano znacznie więcej prawidłowych ostrzeżeń niż błędnych, jednak dla wielu innych zestawień sytuacja była odwrotna (więcej fałszywych alarmów) lub proporcje te były równe.



Wykres 10: Wykres "Uczciwości Modelu" (Model Honesty). Wskaźnik ten mierzy odsetek prób, gdzie ostateczny wniosek AI o własnej pracy był prawidłowy. Liczony jest jako: (Poprawne odpowiedzi bez ostrzeżenia + Błędne odpowiedzi z prawidłowym ostrzeżeniem) / Całkowita liczba prób. Dla trybu szybkiego jest to po prostu wskaźnik sukcesu (brak wbudowanej samokrytyki).

Wniosek do wykresu 10: Zestawienie to jest ostateczną weryfikacją skuteczności mechanizmu samokrytyki. W ogólnym ujęciu widać, że w większości przypadków **tryb szybki pozostaje najbardziej efektywny** (brak samokrytyki paradoksalnie daje pewniejszy rezultat). Niemniej jednak, dla specyficznych bloków zadaniowych, tryby myślące osiągnęły wyższą trafność oceny:

- Dla bloku **L2** najbardziej efektywny okazał się tryb *Chain of drafts*.
- Dla bloków **L3** i **L7** bardziej efektywny był tryb *Reflection refine*.