


1. Zagregowane statystyki ogólne

- Tryb: FAST (Szybki)
- Całkowita liczba testów: 42
- Pełny sukces (Full Pass – wszystkie powtórzenia poprawne): 21 (50.0%)
- Częściowy sukces (Partial Pass – min. 1 powtórzenie poprawne): 29 (69.0%)
- Wskaźnik sukcesu dla pojedynczej próby: 59.5% (125/210 prób)
- Tryb: THINKING (Myślący)
- Całkowita liczba testów: 42
- Pełny sukces (Full Pass – wszystkie powtórzenia poprawne): 12 (28.6%)
- Częściowy sukces (Partial Pass – min. 1 powtórzenie poprawne): 30 (71.4%)
- Wskaźnik sukcesu dla pojedynczej próby: 51.9% (109/210 prób)


Wnioski: Tryb myślący wykazuje mniejszy determinizm i w ogólnym ujęciu częściej popełnia błędy (niższy wskaźnik *Full Pass* oraz niższa skuteczność na poziomie pojedynczych prób). Z drugiej strony wskaźnik *Partial Pass* jest wyższy. Oznacza to, że choć proces jest mniej stabilny, tryb myślący ma potencjał do rozwiązywania **szerszego spektrum problemów** – w przypadku większej liczby zadań udało mu się wygenerować poprawną odpowiedź przynajmniej raz.

2. Analiza skuteczności na poziomie testów i kategorii



Wykres 1: Podwójne mapy ciepła (heatmaps) odwzorowujące dokładne współczynniki sukcesu dla każdego testu. Czarne tło maskuje puste komórki, co pozwala na bezpośrednie wizualne porównanie niezawodności obu trybów.


Wniosek do wykresu 1: Analizując mapę ciepła, warto zwrócić szczególną uwagę na dwie ostatnie pozycje w 1. bloku testowym. Są to zadania o charakterze matematycznym i logicznym. To właśnie w tego typu problemach, wymagających dekompozycji i analitycznego podejścia, wdrożenie narzędzia "myślenia" jest najbardziej uzasadnione i przynosi najlepsze rezultaty.




Wykres 2: Porównawcze wykresy słupkowe przedstawiające wskaźniki sukcesu (0.0–1.0) z podziałem na bloki tematyczne oraz stopień złożoności (Teoria, Kodowanie, CLI).

Wniosek do wykresu 2: Zestawienie to wyraźnie potwierdza, że tryb myślący radzi sobie zauważalnie lepiej w przypadku zadań teoretycznych (Theory) w porównaniu do trybu szybkiego.

3. Analiza czasu przetwarzania (Opóźnienia)



Wykres 3: Histogramy rozkładu czasu przetwarzania (w sekundach) dla każdego trybu, wzbogacone o estymację gęstości (KDE) oraz wskaźniki mediany. Zobrazowany jest tu bezpośredni narzut czasowy generowany przez proces myślenia.



Wykres 4: Rozkład opóźnień przedstawiony za pomocą wykresów pudełkowych z podziałem na pakiety testowe, identyfikujący bloki tematyczne o największym obciążeniu.

Wniosek do wykresów 3 i 4: Zgodnie z oczekiwaniami, tryb myślenia wymaga znacznie więcej czasu na przetworzenie odpowiedzi. Wynika to z dodatkowych kroków analitycznych i alokacji zasobów w procesie dekompozycji zadań, co wprost przekłada się na dłuższe czasy wykonania uwidocznione na wykresach.